Medikal Görüntüleme ile Beyin Kanamalarının Sınıflandırılması: Literatür Taraması

1. Giriş

Bilgisayarlı tomografi (BT), beyin kanamalarının hızlı ve doğru bir şekilde tespit edilmesinde kritik bir görüntüleme yöntemidir. Özellikle travmatik beyin yaralanmaları veya spontan intrakraniyal hemorajilerde, erken tanı hayat kurtarıcıdır. Son yıllarda derin öğrenme ve makine öğrenimi yöntemleri, BT görüntülerinden otomatik olarak kanama tespiti ve sınıflandırması yapmada büyük ilgi görmüştür. Bu ödevde, son yıllarda yapılmış beyin kanamalarının sınıflandırılması çalışmalarını inceleyerek, kullanılan yöntemler, veri setleri ve görüntü işleme teknikleri karşılaştırılmıştır.

2. Literatür Taraması

2.1 Gençtürk ve Ark. (2023)

Bu çalışmada, BT görüntülerinden beyin kanamalarını tespit etmek için **derin öğrenme temelli CNN modelleri** (VGG, ResNet, EfficientNet) kullanılmıştır. Görüntüler normalizasyon işleminden geçirilerek doğrudan CNN modellerine verilmiştir.
Veri seti: PhysioNet BT beyin kanaması veri kümesi.
Sonuç: EfficientNet-B2 modeli, diğer modellere göre daha yüksek doğruluk ve F1 skorları elde etmiştir.
Eksik: Çalışmada kanama alt tipleri ayrı ayrı sınıflandırılmamış, sadece genel kanama tespiti yapılmıştır.

2.2 Altun ve Ark. (2024)

Çalışmada **hafif derin öğrenme modelleri** (DenseNet121, MobileNet, Inception V1) ile BT görüntülerinden otomatik sınıflandırma yapılmıştır. Görüntüler CNN'e doğrudan verilmiş, ön işleme minimal düzeyde tutulmuştur.
Veri seti: Araştırmacıların kendi oluşturduğu BT veri seti.
Sonuç: Model eğitim süresi kısa ve sınıflandırma doğruluğu yüksek bulunmuştur.
Eksik: Veri seti boyutu sınırlı olduğundan modelin genelleştirme yeteneği sınırlı olabilir.

2.3 Ensemble Tabanlı Doku Analizi (2023)

Bu çalışmada BT görüntülerinden **doku öznitelikleri (LBP, texture features)** çıkarılmış ve SVM, Random Forest gibi **makine öğrenimi algoritmaları** ile sınıflandırma yapılmıştır.
Veri seti: Çeşitli akademik BT veri kümeleri.
Sonuç: Doku temelli sınıflandırmalar, CNN'lere göre hâlâ rekabetçi performans göstermiştir.
Eksik: Manuel öznitelik çıkarımı, otomatik öğrenmeye göre esneklikten yoksundur.

2.4 OzNet Hybrid Model (2023)

Bu çalışmada, **OzNet CNN** ile özellik çıkarımı yapılmış, **NCA (Neighborhood Component Analysis)** ile boyut indirgeme uygulanmış ve ardından SVM, KNN, ANN gibi klasik sınıflandırıcılar kullanılmıştır.
Veri seti: Araştırmacıların BT görüntüleri.
Sonuç: OzNet + NCA + ANN kombinasyonu çok yüksek doğruluk (yaklaşık %100) elde etmiştir.
Eksik: Veri seti boyutu ve elde edilme koşulları net olmadığı için genelleştirme sınırlı olabilir.

2.5 Nguyen ve Ark. (2020)

Çalışmada **CNN + LSTM** mimarisi kullanılmıştır. CNN, BT dilimlerinden öznitelik çıkarırken, LSTM 3D BT kesitleri arasındaki ilişkileri öğrenmiştir.
Veri seti: RSNA Intracranial Hemorrhage Challenge veri seti ve CQ500 benchmark veri seti.
Sonuç: Slice-wise ilişkilerin öğrenilmesi, klasik 2D CNN'e göre daha iyi sonuç vermiştir.
Eksik: Modelin hesaplama karmaşıklığı yüksek, eğitim süresi uzun olabilmektedir.

---

3. Karşılaştırma ve Genel Eksiklikler

Çalışma	Yöntem	Veri Seti	Avantaj	Dezavantaj
Gençtürk et al.	CNN (EfficientNet vb.)	PhysioNet	Yüksek doğruluk	Alt tip ayrımı yok
Altun et al.	Lightweight CNN	Kendi veri	Kısa eğitim süresi	Veri sınırlı
Texture Ensemble	ML + LBP	Çeşitli BT	Basit & etkili	Otomatik öğrenme eksik
OzNet Hybrid	CNN + ML	Araştırma seti	Çok yüksek skor	Veri seti belirsiz
CNN-LSTM	CNN + LSTM	RSNA + CQ500	3D ilişkiler güçlü	Hesaplama ağır

Genel Eksiklikler

1. Çoğu çalışma sadece "kanama var/yok" tespiti yapıyor, alt tip sınıflandırması eksik.
2. Veri setleri genellikle küçük veya özel veri ile sınırlı, bu da genelleştirmeyi zorlaştırıyor.
3. 3D BT analizleri sınırlı, çoğu çalışma 2D slice bazlı.
4. Model genelleme ve klinik validasyon çoğu çalışmada yeterince test edilmemiş.

---

4. Sonuç

Literatürde, BT görüntüleri üzerinde beyin kanamalarının sınıflandırılması için **CNN ve derin öğrenme modelleri** öne çıkmaktadır. Hafif CNN'ler kısa eğitim süresi ve makul doğruluk sağlarken, hybrid ve 3D ilişkili modeller yüksek doğruluk sağlamakta ancak hesaplama yükü fazladır. Gelecekte yapılacak çalışmaların:

- Alt tip sınıflandırmalarına odaklanması,
- Daha geniş ve çeşitlendirilmiş veri setleri kullanması,
- 3D volumetrik analiz ve gerçek klinik ortam validasyonu içermesi önerilmektedir.

5. Referanslar

1. Gençtürk, T. H., GülAğız, F. K., & Kaya, İ. (2023). *Deep learning methods applied to CT scans for brain hemorrhage diagnosis*. Journal of Intelligent Systems: Theory and Applications. Link
2. Altun, E. B., et al. (2024). *Lightweight deep learning model for CT brain hemorrhage*. Ordu Üniversitesi Bilim ve Teknoloji Dergisi. Link
3. Ensemble-based texture classification (2023). *Biomedical Signal Processing and Control*. Link
4. OzNet hybrid classification (2023). *International Journal of Imaging Systems and Technology*. Link
5. Nguyen, N. T., et al. (2020). *CNN-LSTM architecture for ICH detection*. arXiv. Link