

**ADİYAMAN ÜNİVERSİTESİ MÜHENDİSLİK  
FAKÜLTESİ BİLGİSAYAR MÜHENDİSLİĞİ  
BÖLÜMÜ MEDİKAL GÖRÜNTÜ İŞLEME DERSİ  
2025-2026 FİNAL PROJESİ RAPORU**

**BİLGİSAYARLI TOMOGRAFİ GÖRÜNTÜLERİNDEN  
DERİN ÖĞRENME İLE BEYİN KANAMASI TESPİTİ**

İlayda Karaaslan      Nisa Hanım Şanal      Sevin Hasan



## ÖZET

Bu çalışmada, acil servislerde hayati önem taşıyan beyin kanamalarının bilgisayarlı tomografi (BT) görüntüleri üzerinden otomatik olarak tespit edilmesi amaçlanmıştır. Proje kapsamında, Google Drive üzerinde organize edilen toplam 4.848 adet beyin BT görüntüsünden oluşan bir veri seti kullanılmıştır. Bu veri setinin %80'i modelin eğitimi, %20'si ise başarısını kontrol etmek amacıyla ayrılmıştır. Bilgisayarlı görme çalışmalarında yüksek başarı gösteren ResNet18 mimarisi ana odak olarak seçilmiş; adil bir karşılaştırma yapabilmek amacıyla AlexNet, DenseNet121, VGG16 ve ResNet50 mimarileri de aynı veri setiyle eğitilmiştir. PyTorch kütüphanesi kullanılarak yapılan eğitimler sonucunda, tüm modellerin doğrulama başarıları kıyaslanmıştır. Geliştirilen derin öğrenme tabanlı bu sistemlerin, tıbbi süreçlerde doktorlara yardımcı olabilecek güvenilir bir klinik karar destek aracı olma potansiyeline sahip olduğu görülmüştür.

*Anahtar Kelimeler: Beyin Kanaması, Bilgisayarlı Tomografi, Derin Öğrenme, Evrişimli Sinir Ağları (CNN), Çoklu Mimari Karşılaştırması.*

## 1. GİRİŞ

Beyin kanaması, beyindeki damarların yırtılması sonucu kanın beyin dokusuna sızmasıyla oluşan ve hızlı müdahale edilmediğinde kalıcı hasarlara veya ölüme yol açabilen ciddi bir sağlık sorunudur. Acil servislerde bu durumun hızla teşhis edilmesi için en sık kullanılan yöntem Bilgisayarlı Tomografi (BT) taramalarıdır. Ancak yoğun acil servis ortamlarında yüzlerce BT kesitini incelemek uzman doktorlar için zaman alıcı olabilmekte ve yorgunluğa bağlı gözden kaçma riski barındırmaktadır.

Son yıllarda yapay zeka ve derin öğrenme teknolojileri, medikal görüntülerin analiz edilmesinde çok büyük başarılar göstermektedir. Özellikle Evrişimli Sinir Ağları (CNN), görüntüleri inceleyerek insan gözünün fark etmekte zorlanacağı detayları yakalayabilmektedir. Bu proje kapsamında, derin öğrenme yöntemleri kullanılarak BT görüntülerinden beyin kanamalarının otomatik olarak tespit edilmesi hedeflenmiştir. Çalışmada tek bir modelle yetinilmeyip; bilgisayarlı görme dünyasında kabul görmüş 5 farklı yapay zeka mimarisi (ResNet18, AlexNet, DenseNet121, VGG16, ResNet50) aynı şartlar altında eğitilmiş ve hangisinin daha güvenilir sonuçlar verdiği kıyaslanmıştır.

## 2. LİTERATÜRDEKİ ÖNEMLİ ÇALIŞMALAR

### 2.1. Gençtürk ve Arkadaşları (2023)

Gençtürk ve arkadaşları, PhysioNet BT veri kümesi üzerinde VGG16, ResNet50 ve EfficientNet-B2 modellerini karşılaştırmıştır. Çalışmada görüntüler normalizasyon işleminden geçirilmiş ve doğrudan CNN modellerine verilmiştir. EfficientNet-B2 en yüksek doğruluk ve F1 skorlarını elde etmiştir; ancak kanama alt tiplerinin ayrı ayrı sınıflandırılmaması önemli bir eksiklik olarak vurgulanmıştır..

### 2.2. Altun ve Arkadaşları (2024)

Altun ve arkadaşları, hafif derin öğrenme modelleri olan DenseNet121, MobileNet ve Inception V1 ile BT görüntülerinden otomatik sınıflandırma gerçekleştirmiştir. Ön işleme minimal düzeyde tutularak görüntüler doğrudan CNN'e verilmiştir. Model eğitim süresi kısa ve sınıflandırma doğruluğu yüksek olmakla birlikte, veri setinin sınırlı boyutu modelin genelleştirme yeteneğini kısıtlamaktadır..

### 2.3. Ensemble Tabanlı Doku Analizi (2023)

Bu çalışmada BT görüntülerinden LBP (Local Binary Pattern) ve doku öznelikleri çıkarılmış; SVM ve Random Forest gibi klasik makine öğrenimi algoritmaları ile sınıflandırma yapılmıştır. Doku temelli yaklaşımın CNN'lerle rekabetçi performans sergilediği görülmüş; ancak manuel öznelik çıkarımının otomatik öğrenmeye kıyasla esneklik eksikliği taşıdığı belirtilmiştir.

### 2.4. OzNet Hibrit Model (2023)

OzNet CNN mimarisi ile özellik çıkarımı yapılmış, NCA (Neighborhood Component Analysis) ile boyut indirgeme uygulanmış; ardından SVM, KNN ve ANN sınıflandırıcıları kullanılmıştır. OzNet + NCA + ANN kombinasyonu yaklaşık %100 doğruluk bildirmiştir; ancak veri setinin boyutu ve elde edilme koşullarının şeffaf olmaması sonuçların genelleştirilebilirliğini sorgulamaktadır.

### 2.5. Nguyen ve Arkadaşları (2020) — CNN + LSTM

RSNA Intracranial Hemorrhage Challenge ve CQ500 veri setleri üzerinde CNN+LSTM hibrit mimarisi denenmiştir. CNN dilim bazlı öznelikleri çıkarırken LSTM, 3B BT kesitleri arasındaki temporal ilişkileri öğrenmiştir. Dilim-arası ilişkilerin modellenmesi klasik 2B CNN'e göre üstün sonuç vermiş; ancak modelin hesaplama karmaşıklığı ve eğitim süresi önemli dezavantajlar olarak öne çıkmaktadır.

### 2.6. Fan ve Arkadaşları (2024) — DTViT

Fan ve arkadaşları, Vision Transformer (ViT) mimarisine dayalı Dual-Task Vision Transformer (DTViT) modelini önermiştir. Model; hem kanamanın varlığını belirlemek hem de konumunu (derin, subkortikal, lobar) sınıflandırmak üzere iki görevli bir yapıda tasarlanmıştır. Gerçek dünya klinik verileriyle doğrulanan model, acil tanı uygulamalarında güvenilir bir yapay zeka aracı olarak değerlendirilmektedir..

### 3. MATERİYAL VE YÖNTEM

#### 3.1. Veri Seti ve Sınıf Dağılımı

Bu çalışmada, bilgisayarlı tomografi (BT) görüntüleri üzerinden beyin kanaması tespiti yapabilmek amacıyla literatürde sıkça başvurulmuş ve Kaggle platformu üzerinde açık kaynaklı olarak sunulan kapsamlı bir veri seti kullanılmıştır. Toplam 4.848 adet medikal görselden oluşan bu veri kümesi, modellerin adil test edilebilmesi için dengeli bir kurguya sahiptir. Kanama odağı içeren kesitlerin yer aldığı "Kanamalı" sınıfında 2.383 görsel (%49.2), tamamen sağlıklı beyin kesitlerinin yer aldığı "Normal" sınıfında ise 2.465 görsel (%50.8) bulunmaktadır.

| Sınıf    | Görüntü Sayısı | Oran (%) |
|----------|----------------|----------|
| KANAMALI | 2.383          | %49.2    |
| NORMAL   | 2.465          | %50.8    |
| TOPLAM   | 4.848          | %100.0   |

Tablo 1. Veri Seti Sınıf Dağılımı ve Oranları

Geliştirme ortamı olarak Google Colab tercih edildiği için, veri setinin tamamı ilk aşamada Google Drive üzerindeki `/MyDrive/Data` yoluna yüklenmiş ve bulut sistemine bağlanmıştır. Klasör mimarisi, PyTorch kütüphanesinin veri yükleme standartlarına tam uyumlu olacak şekilde, her sınıfın kendi adını taşıyan alt klasörlerde tutulduğu organize bir yapıda kurgulanmıştır.

#### 3.2. Derin Öğrenme Mimarisi

Bu çalışmada, bilgisayarlı tomografi (BT) görüntüleri üzerinden beyin kanaması tespiti yapabilmek amacıyla tek bir modele bağımlı kalınmamış; literatürde başarısını kanıtlamış 5 farklı Evrişimli Sinir Ağı (CNN) mimarisi seçilmiştir. Bu mimariler; derin ağlardaki gradyan kaybolması problemini aşan ResNet18, derin öğrenmenin tarihsel referans noktası olan AlexNet, katmanlar arası yoğun bağlantılarıyla öne çıkan DenseNet121, kararlı öznetelik çıkarımı sağlayan VGG16 ve daha karmaşık öznetelikleri yakalayabilen 50 katmanlı derin ResNet50 mimarileridir.

Tercih edilen tüm bu mimarilerin orijinal çıktı katmanları, ImageNet veri setindeki 1000 farklı sınıfı tahmin etmek üzere tasarlanmıştır. Bu nedenle, projenin amacına uygun olarak tüm modellerin son tam bağlantılı katmanları (Fully Connected Layers) kod seviyesinde yeniden tasarlanmış ve bizim veri setimizdeki iki sınıflı ("Kanamalı" ve "Normal") yapıya uyumlu hale getirilmiştir.

### 3.3. Model Mimarisi

Bu çalışmada, bilgisayarlı tomografi görüntülerinden beyin kanaması tespiti yapabilmek amacıyla tek bir mimariye bağımlı kalınmamış; literatürde derin öğrenme ve bilgisayarlı görme (computer vision) alanında rüştünü ispatlamış 5 farklı Evrişimli Sinir Ağı (CNN) modeli mimari havuzuna dahil edilmiştir. Tercih edilen modellerin yapısal özellikleri ve projeye entegrasyon detayları şu şekildedir:

**ResNet18 Mimarisi:** Derin sinir ağlarında katman sayısı arttıkça ortaya çıkan gradyan kaybolması (vanishing gradient) problemini "artık bağlantılar" (shortcut/residual connections) mantığıyla çözen, 18 katmanlı efektif bir mimaridir.

**AlexNet Mimarisi:** 5 evrişim katmanı (convolutional layer) ve ardışık tam bağlantılı katmanlardan oluşan, derin öğrenmenin medikal görüntülemeindeki tarihsel başarımını kıyaslamak adına temel referans (baseline) noktası olarak seçilen klasik bir mimaridir.

**DenseNet121 Mimarisi:** Klasik CNN yapılarından farklı olarak, her katmanın kendinden önceki tüm katmanların öznelik haritalarını girdi olarak aldığı yoğun bağlantılı (dense connectivity) bir ağ yapısına sahiptir. Bu sayede daha az parametreyle tıbbi görüntülerdeki ince detayları yakalayabilmektedir.

**VGG16 Mimarisi:** Ardışık 3x3 boyutundaki küçük evrişim filtreleri ve havuzlama katmanlarıyla (pooling) kurgulanmış homojen bir yapıya sahiptir. Parametre sayısının yüksek olması nedeniyle hesaplama maliyeti oluştursa da, medikal görsellerden oldukça kararlı öznelikler çıkarabilmektedir.

**ResNet50 Mimarisi:** ResNet18 yapısının daha derin ve karmaşık bir versiyonu olup 50 katmandan oluşmaktadır. İçerdiği "bottleneck" (darboğaz) katman tasarımları sayesinde tomografi kesitlerindeki çok daha karmaşık ve soyut öznelikleri öğrenme kapasitesine sahiptir.

Kullanılan tüm bu hazır mimarilerin orijinal çıktı katmanları (FC - Fully Connected), ImageNet veri setindeki 1000 farklı nesne sınıfını ayırt etmek üzere kurgulanmıştır. Projenin amacıyla uyumlu hale getirilmesi adına, tüm bu 5 modelin son sınıflandırma katmanları kod seviyesinde (`nn.Linear`) yeniden tasarlanmış ve bizim veri setimizdeki iki sınıflı ("Kanamalı" ve "Normal") doğrusal çıktı yapısına dönüştürülmüştür.

#### 4. DENEYSEL SONUÇLAR

Bu projede önerilen derin öğrenme modelleri, toplam 4.848 adet gri tonlu beyin BT görüntüsü kullanılarak eğitilmiş ve test edilmiştir. Veri setinde kanamalı ve normal görüntü bulunmaktaydı. Eğitim sırasında veri artırma teknikleri ön işleme olarak dinamik şekilde uygulanmıştır. Modeller, 15 epoch boyunca Adam optimizatörü ile eğitilmiş ve kayıp fonksiyonu olarak Binary Cross-Entropy (BCEWithLogitsLoss) kullanılmıştır. Eğitim ve test aşamalarında öğrenme oranı 0.001 olarak ayarlanmıştır. Elde edilen sonuçlar, modellerin beyin kanamalarını başarılı şekilde tespit edebildiğini göstermektedir. Modellerin genel performansını kıyaslamak adına test veri seti üzerinde hesaplanan değerlendirme metrikleri Tablo 2'de sunulmuştur.

| Model Mimarisi | Accuracy (Doğruluk) | F1 Score | Precision (Keskinlik) | Recall (Duyarlılık) |
|----------------|---------------------|----------|-----------------------|---------------------|
| DenseNet121    | 0.9340              | 0.9310   | 0.9280                | 0.9340              |
| ResNet50       | 0.9280              | 0.9250   | 0.9210                | 0.9290              |
| ResNet18       | 0.9150              | 0.9120   | 0.9080                | 0.9160              |
| VGG16          | 0.8920              | 0.8890   | 0.8850                | 0.8930              |
| AlexNet        | 0.8560              | 0.8510   | 0.8460                | 0.8570              |

Tablo 2. Modellerin Performans ve Değerlendirme Metrikleri

Bu metriklerin hesaplanması şu formüller doğrultusunda yapılmaktadır:

$$\text{Doğruluk (Accuracy)} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Keskinlik (Precision)} = TP / (TP + FP)$$

$$\text{Duyarlılık (Recall)} = TP / (TP + FN)$$

$$\text{F1 Skoru} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Burada, TP doğru pozitifleri (kanamalı tespitleri), TN doğru negatifleri (normal tespitleri), FP yanlış pozitifleri (normal iken kanamalı denilenleri), FN ise yanlış negatifleri (kanamalı iken normal denilenleri) ifade etmektedir.

#### 4.1. Model Eğitimi


Model eğitimi, iki sınıflandırma problemine uygun olarak kurgulanan döngü üzerinden gerçekleştirilmiştir. Modeller, toplam 15 epoch boyunca eğitilmiştir. Her epoch sonunda hem eğitim hem de doğrulama veri setleri üzerinde doğruluk ve kayıp değerleri hesaplanmıştır. Eğitimi tamamlanan modellerin çıktıları, sigmoid aktivasyon fonksiyonu ile elde edilmiş ve 0.5 eşik değeri kullanılarak sınıflandırma yapılmıştır. Bu eşik üzerindeki değerler "Kanama VAR", altındaki değerler ise "Kanama YOK" olarak etiketlenmiştir.

Ayrıca modellerin daha iyi genelleme yapabilmesi için eğitim verisine çeşitli veri artırma (augmentation) teknikleri uygulanmıştır: Yatay çevirme (RandomHorizontalFlip) ve Rasgele döndürme (RandomRotation). Bu ön işlemler sayesinde modeller, farklı varyasyonlardaki görüntülere karşı daha dayanıklı hale gelmiştir. Eğitim verisi üzerinde ortalama doğruluk oranı modellere göre %88 ile %95 arasında değişiklik gösterirken; DenseNet121 ve ResNet50 gibi yüksek parametrelili modellerin eğitim süreçlerinde Google Colab ortamındaki T4 GPU donanım desteği aktif edilerek optimizasyon sağlanmıştır.

#### 4.2. Modelin Tahmin Örnekleri

Aşağıda modellerin test verilerinden iki farklı örnek görüntü üzerindeki tahmin sonuçları yer almaktadır. Görsel 1'de kanamasız, Görsel 2'de ise kanamalı bir beyin BT görüntüsü bulunmaktadır. Her iki görüntü için de ResNet18 modelin tahmini ve ilgili olasılık değeri başlıkta belirtilmiştir.

Model Tahmini: Kanama YOK (olasılık: 0.56)



Görsel 1 (Veri Setinden)

Model Tahmini: Kanama VAR (olasılık: 0.74)



Görsel 2 (Veri Setinden)

## 5. SONUÇ

Bu çalışmada, bilgisayarlı tomografi (BT) görüntüleri üzerinden beyin kanaması tespiti yapabilmek amacıyla literatürde bilgisayarlı görme alanında rüştünü ispatlamış 5 farklı derin öğrenme mimarisi (DenseNet121, ResNet50, ResNet18, VGG16 ve AlexNet) PyTorch kütüphanesi kullanılarak eğitilmiş ve performansları adil bir şekilde kıyaslanmıştır. Modellerin test veri seti üzerinde sergiledikleri genel doğruluk (Accuracy) başarımları toplu olarak Tablo 3'te özetlenmiştir.

| Model Mimarisi | Katman Derinliği | Test Doğruluğu (Accuracy) | Performance Sıralaması |
|----------------|------------------|---------------------------|------------------------|
| DenseNet121    | 121 Katman       | %93.40                    | 1 (En Başarılı)        |
| ResNet50       | 50 Katman        | %92.80                    | 2                      |
| ResNet18       | 18 Katman        | %91.50                    | 3                      |
| VGG16          | 16 Katman        | %89.20                    | 4                      |
| AlexNet        | 8 Katman         | %85.60                    | 5                      |

Tablo 3. Tüm Derin Öğrenme Mimarilerinin Genel Doğruluk Karşılaştırması

Deneysel sonuçlar ve Tablo 3 incelendiğinde, projenin en başarılı modeli %93.40 doğruluk oranı ile DenseNet121 mimarisi olmuştur. DenseNet121'in bu başarısı, katmanlar arası yoğun bağlantı yapısı sayesinde tomografi kesitlerindeki en ince ve soyut kanama odaklarını bile kayıpsız bir şekilde öznetelik haritasına aktarabilmesinden kaynaklanmaktadır. Onu çok yakın bir performansla takip eden 50 katmanlı ResNet50 (%92.80) modeli de derin mimarilerin medikal teşhisteki gücünü kanıtlamıştır. Diğer taraftan, çalışmanın temel referans (baseline) noktası olarak seçilen AlexNet mimarisi ise daha sıkı yapısı nedeniyle %85.60 doğruluk payında kalarak en düşük performansı sergilemiştir.

Sonuç olarak, bu proje beyin kanaması gibi hızlı müdahale gerektiren kritik süreçlerde, derin öğrenme tabanlı sistemlerin radyologlara güvenilir bir klinik karar destek mekanizması sunabileceğini açıkça ortaya koymuştur.



## KAYNAKLAR

- [1] Feigin, V. L., et al. (2021). World Stroke Organization: Global burden of stroke. *The Lancet Neurology*, 20(10), 795-820.
- [2] Fan, Z., et al. (2024). Dual-task vision transformer for intracerebral hemorrhage identification and subtype classification in non-contrast head CT scans. *Medical Image Analysis*, 90, 102940.
- [3] He, K., Zhang, S., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR*, 770-778. (*ResNet Mimarisi Kaynağı*)
- [4] Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *ICLR*, arXiv:1409.1556. (*VGG Mimarisi Kaynağı*)
- [5] Huang, G., Liu, Z., van der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. *CVPR*, 4700-4708. (*DenseNet Mimarisi Kaynağı*)
- [6] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep CNNs. *NeurIPS*, 25, 1097-1105. (*AlexNet Mimarisi Kaynağı*)
- [7] Gençtürk, T. H., Gülağız, F. K., & Kaya, İ. (2023). Deep learning methods applied to CT scans for brain hemorrhage diagnosis. *Journal of Intelligent Systems: Theory and Applications*.
- [8] Altun, E. B., et al. (2024). Lightweight deep learning model for CT brain hemorrhage. *Ordu Üniversitesi Bilim ve Teknoloji Dergisi*.
- [9] Ensemble-based texture analysis for brain hemorrhage classification. (2023). *Biomedical Signal Processing and Control*.
- [10] OzNet hybrid CNN-ML classification model. (2023). *International Journal of Imaging Systems and Technology*. (*Sürüm Hatası Düzenlenen Kaynak*)
- [11] Paszke, A., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*.
- [12] Nguyen, N. T., et al. (2020). CNN-LSTM architecture for intracranial hemorrhage detection. *arXiv*.
- [13] Abdulkader, M. (2023). Brain CT Hemorrhage Dataset. *Kaggle*.  
<https://www.kaggle.com/datasets/abdulkader90/brain-ct-hemorrhage-datas>  
[et](#) (*Kullanılan Veri Seti Kaynağı*)

İLAYDA KARAASLAN 232104042

NİSA HANIM ŞANAL 232104012

SEVİN HASAN 232104187